ETH Kurssityö 2025

Projekti tehty ryhmätyönä,
Oma osuuteni on ensimmäinen työ

Sisällys

1 Maanjäristyksen paikantaminen **1**

1.1 Yhteenveto 1

1.2 Teoria 2

1.2.1 Havaintomalli 2

1.2.2 MAP-estimaatti epälineaariselle havaintomallille 2

1.2.3 ML-estimaatti epälineaariselle havaintomallille 3

1.3 Tulokset 3

1.3.1 ML-estimaattien tulokset 4

1.3.2 MAP-estimaattien tulokset 6

2 Lentokoneen paikan estimointi tutkadatasta **11**

2.1 Yhteenveto 11

2.2 Teoria 12

2.3 Tulokset 14

Luku 1

Maanjäristyksen paikantaminen

1.1 Yhteenveto

Tehtävänä oli estimoida maanjäristyksen lähde hyödyntämällä kuuden seismisen mittausaseman dataa. Seismiset mittausasemat asetettiin karteesiseen koordinaatistoon, ja mittauspisteet olivat sekunteja maanjäristyksen alkamisajasta $t = 0$. Maanjäristyksen havaintomalli oli epälineaarinen, joten estimointimenetelmä oli Gauss-Newtonin menetelmä. Estimaattoreina olivat maximum a posteriori -estimaattori (MAP) ja maximum likelihood -estimaattori (ML).

Maanjäristyksen havaintomalli muodostettiin oletuksella, että maanjäristys kulkee tasaisella maalla vakionopeudella. Pistemäisellä maanjäristyksen lähteellä seisminen aalto kulkee ympyrämäisesti siten, että järistyksen lähde on ympyrän keskipiste ja ympyrän säde kasvaa vakionopeudella.

Tuloksista havaittiin, että MAP-estimaatti on tarkka, kun prioritieto on "hyvää", ja ML-estimaatti on tarkka, kun havaintoja on riittävä määrä. Kun MAP-estimaatissa prioritieto on huonoa, maanjäristyksen estimaatti poikkeaa jopa posterioritiheyden maksimista reilusti. Kun taas ML-estimaatissa havaintojen lukumäärä on liian pieni (1 kpl havaintoja), ML-estimaatilla on mahdotonta paikantaa maanjäristyksen lähdettä. Johtopäätöksenä voidaan todeta, että useammalla mittauspisteellä ilman tarkempaa prioritietoa kannattaa hyödyntää ML-estimaattoria, kun taas vähäisemmillä mittauspisteillä ja hyvällä prioritiedolla MAP-estimaattorilla saadaan luotua tarkempaa tietoa.

1.2 Teoria

1.2.1 Havaintomalli

Lähdetään liikkeelle havaintomallista, jonka oletuksena on additiivinen kohina. Havaintomalli on muotoa

$$z = h(\theta) + \varepsilon, \tag{1.2.1}$$

missä z on havainnoista muodostettu vektori, h on mallifunktio, θ on estimoitava parametri ja ε on kohina. Oletetaan, että maanjäristyksen lähde on pistemäinen, ja seismiset aallot kulkevat tasamaalla pallosymmetrisesti lähteen ympärillä. Lisäksi seismisen aallon vauhti on vakio. Tällöin saadaan havaintomalliksi

$$\begin{aligned} t_i &= h(\mathbf{s}) + \varepsilon_i \\ &= \frac{\|\mathbf{r}_i - \mathbf{s}\|}{v} + \varepsilon_i \\ &= \frac{\sqrt{(x_{r_i} - x_s)^2 + (y_{r_i} - y_s)^2}}{v} + \varepsilon_i, \end{aligned} \tag{1.2.2}$$

missä t_i, $i = 1, \ldots, 6$ ovat ajat, jolloin seismiset aallot ovat osuneet seismometriin, r_i ovat seismometrien paikat (vektori ilmaistu myös komponenteittain), $\mathbf{s}$ on maanjäristyksen lähteen paikka (ilmaistu komponenteittain). Havaitaan, että havaintomalli on epälineaarinen maanjäristyksen lähteen suhteen.

1.2.2 MAP-estimaatti epälineaariselle havaintomallille

Parametrien estimointi epälineaarisesta havaintomallista on mahdollista esimerkiksi Gauss-Newtonin menetelmällä. Gauss-Newtonin menetelmä on iteraatiomenetelmä, joka soveltuu epälineaariseen MAP-estimaatin määrittämiseen tai vastaavasti ML-estimaatin määrittämiseen. Määritellään ensin MAP-estimaatti maanjäristyksen lähteelle.

Oletetaan, että maanjäristyksen lähde $\mathbf{s}$ ja mittauksiin liittyvä kohina ε ovat normaalijakautuneita satunnaismuuttujia. Lisäksi oletetaan, että $E\{\varepsilon\} = 0$. Tällöin MAP-estimaatin $(j+1)$. iteraatio on muotoa

$$\hat{\mathbf{s}}_{j+1} = \hat{\mathbf{s}}_j + (J_j^T C_\varepsilon^{-1} J_j + C_\mathbf{s}^{-1})^{-1} (J_j^T C_\varepsilon^{-1} (t - h(\hat{\mathbf{s}}_j)) - C_\mathbf{s}^{-1} (\hat{\mathbf{s}}_j - \eta_\mathbf{s})), \tag{1.2.3}$$

missä J_j on havaintomallin Jacobin matriisi estimoitavien parametrien suhteen, C_ε on kohinan kovarianssimatriisi, $C_\mathbf{s}$ on priorin kovarianssimatriisi ja $\eta_\mathbf{s}$ on priorin odotusarvo. Jacobin

matriisin i:nnes rivi on muotoa

$$J_{j,i} = \frac{1}{v}\begin{bmatrix} \frac{x_s - x_{r,i}}{\|\mathbf{r}-\mathbf{s}\|} & \frac{y_s - y_{r,i}}{\|\mathbf{r}-\mathbf{s}\|} \end{bmatrix}. \tag{1.2.4}$$

Estimaattia iteroidaan niin monta kertaa, että estimaatti suppenee.

Posterioritiheys

Posterioritiheyden $f(\mathbf{s}|t)$ määrittämiseksi tarvitaan uskottavuusfunktio $f(t|\mathbf{s})$ sekä prioritiheys $f_{\mathbf{s}}(\mathbf{s})$. Kun oletetaan, että priori $\mathbf{s}$ ja kohina ε ovat riippumattomia satunnaismuuttujia, saadaan uskottavuusfunktioksi

$$f(t|\mathbf{s}) = f_{\varepsilon}(t - h(\mathbf{s})), \tag{1.2.5}$$

missä f_{ε} on kohinan tiheysfunktio. Tällöin posterioritiheydeksi saadaan Bayesin kaavan mukaisesti

$$f(\mathbf{s}|t) = \frac{f(\mathbf{s}) f_{\varepsilon}(t - h(\mathbf{s}))}{f(t)}, \tag{1.2.6}$$

missä $f(t)$ on havaintojen tiheysfunktio. Kuitenkin havaitaan, että havaintojen tiheysfunktio on vain skaalaavana tekijänä, jolloin voidaan esittää posterioritiheys vastaamaan

$$f(\mathbf{s}|t) \propto f(\mathbf{s}) f_{\varepsilon}(t - h(\mathbf{s})). \tag{1.2.7}$$

Tässä työssä tiheysfunktiot esitetään skaalaamattomina.

1.2.3 ML-estimaatti epälineaariselle havaintomallille

ML-estimaatti voidaan määritellä vastaavasti Gauss-Newtonin menetelmällä. Oletukset säilyvät muuten vastaavina kuin MAP-estimaatissa, mutta prioritietoa ei ole. Tällöin ML-estimaatin $(j+1)$:s iteraatio on muotoa

$$\hat{\mathbf{s}}_{j+1} = \hat{\mathbf{s}}_j + (J_j^T C_{\varepsilon}^{-1} J_j)^{-1} (J_j^T C_{\varepsilon}^{-1} (t - h(\hat{\mathbf{s}}_j))). \tag{1.2.8}$$

Samoin kuin MAP-estimaatissa, ML-estimaattia iteroidaan niin pitkään, että estimaatti suppenee. Uskottavuusfunktio on sama kuin posterioritiheyden yhteydessä esitelty yhtälö (1.2.5).

1.3 Tulokset

Virheen kovarianssina käytettiin kaikissa tuloksissa

$$C_\varepsilon = 0.1^2 I, \tag{1.3.1}$$

missä I on yksikkömatriisi. Tehtävänannon mukainen prioriodotusarvo on

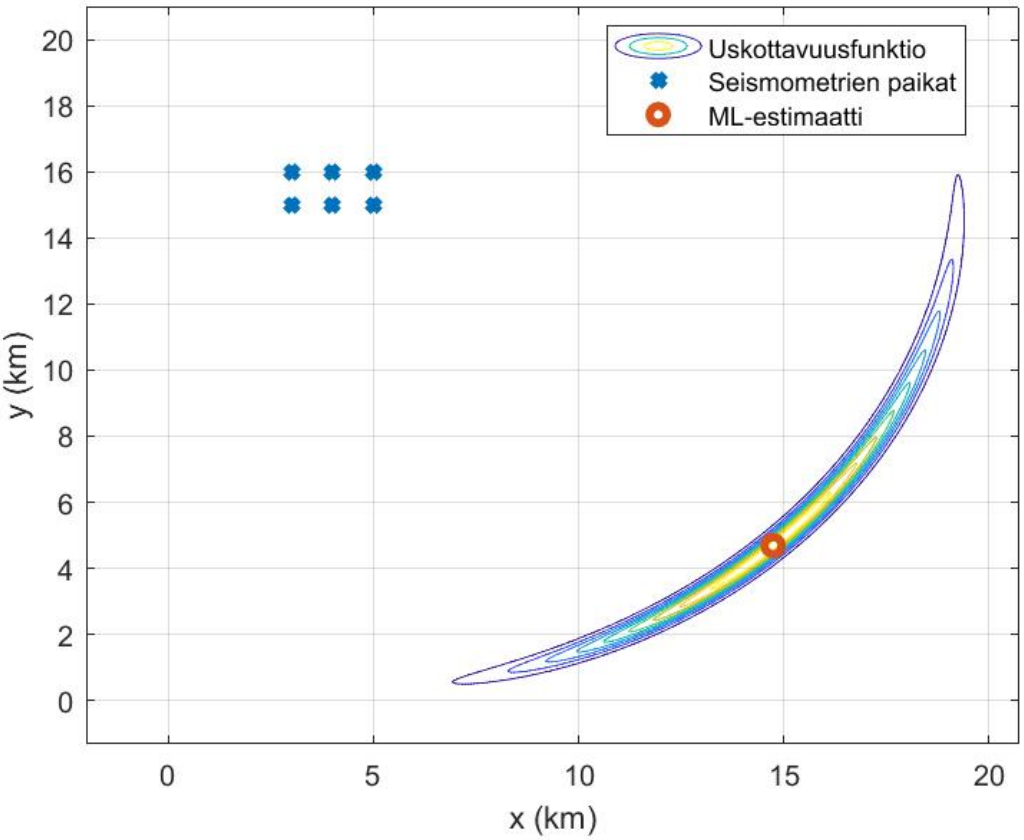
$$\eta_{\mathbf{s}} = \begin{bmatrix} 16 \\ 6 \end{bmatrix} \tag{1.3.2}$$

ja priorikovarianssi

$$C_{\mathbf{s}} = \begin{bmatrix} 1 & 0.7 \\ 0.7 & 1 \end{bmatrix}. \tag{1.3.3}$$

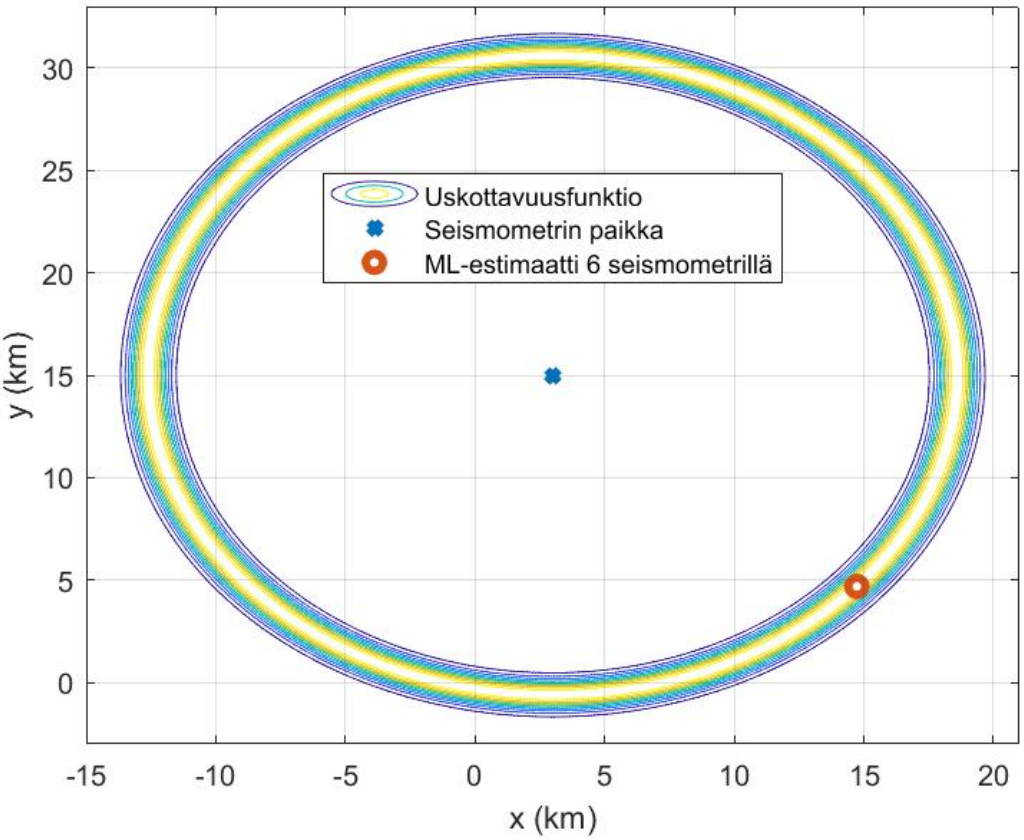
1.3.1 ML-estimaattien tulokset

Suurimman uskottavuuden menetelmällä estimoitiin kahdenlaisia tuloksia. Suurimman uskottavuuden menetelmällä estimaatti saatiin kuudelta seismiseltä mittausasemalta saadun datan pohjalta (Kuva 1.1). Data esitettiin sekunteina maanjäristyksen alkamisesta. Lisäksi kuvaan 1.1 tehtiin korkeuskäyräkuvaaja, joka havainnollistaa tilanteen uskottavuusfunktiota. Lisäksi uskottavuusfunktion korkeuskäyräkuvaaja piirrettiin, kun mittauksista käytettiin vain yhtä seismistä mittausasemaa (Kuva 1.2.



Kuva 1.1: ML-estimaatti ja uskottavuusfunktio, kun havaintoja on 6 kappaletta, ja mittauskohinan kovarianssi sekä odotusarvo on määritelty tehtävänannon mukaisesti.

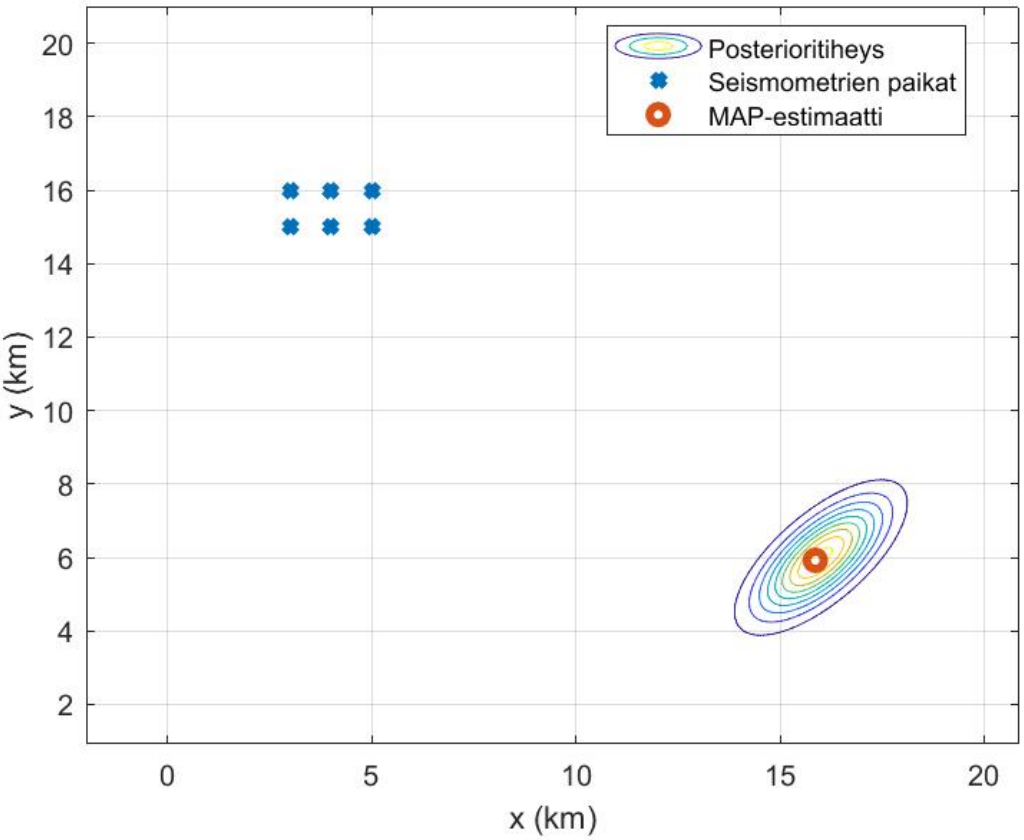
Kuvia 1.1 ja 1.2 vertaillessa huomataan, kuinka ML-estimaatissa useamman mittauksen käyttäminen antaa huomattavasti tarkempia tuloksia kuin vain yksittäisen mittauspisteen käyttäminen. Yhden mittauksen ML-estimaatista ei voi sanoa käytännössä mitään uskottavuusfunktion perusteella.



Kuva 1.2: Maanjäristyksen lähteen uskottavuusfunktio, kun on mittauksista vain yksi on otettu huomioon. Lisäksi kuvaan on piirretty ML-estimaatti 6 mittauksella.

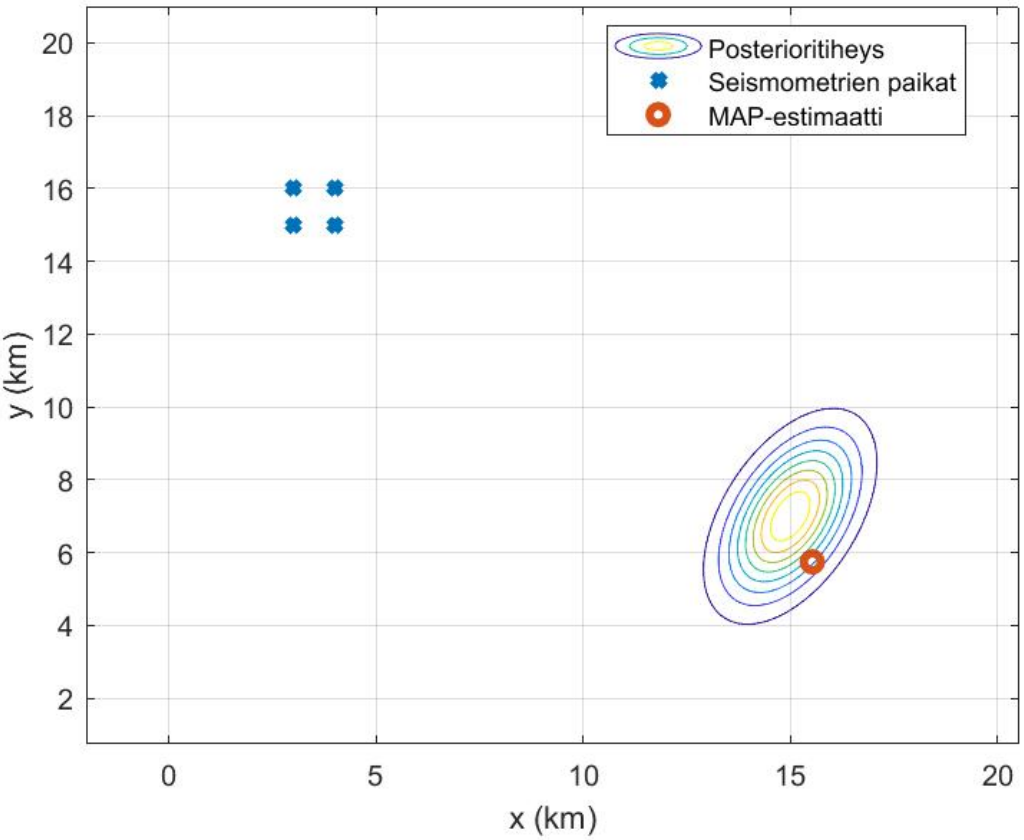
1.3.2 MAP-estimaattien tulokset

MAP-menetelmällä estimoitiin maanjäristyksen lähdettä muuttamalla mittauksien lukumäärää sekä prioritietoja. Kuvassa 1.3 käytettiin kaikkia kuutta (6) mittausta ja tehtävänannossa annettuja prioritietoja (yhtälöt (1.3.2) ja (1.3.3)). Kuvasta nähdään, että posterioritiheys on maltillinen ja MAP-estimaatti vastaa posterioritiheyden maksimikohtaa. Lisäksi MAP-estimaatti on hyvin lähellä ML-estimaattia kuvassa 1.1.

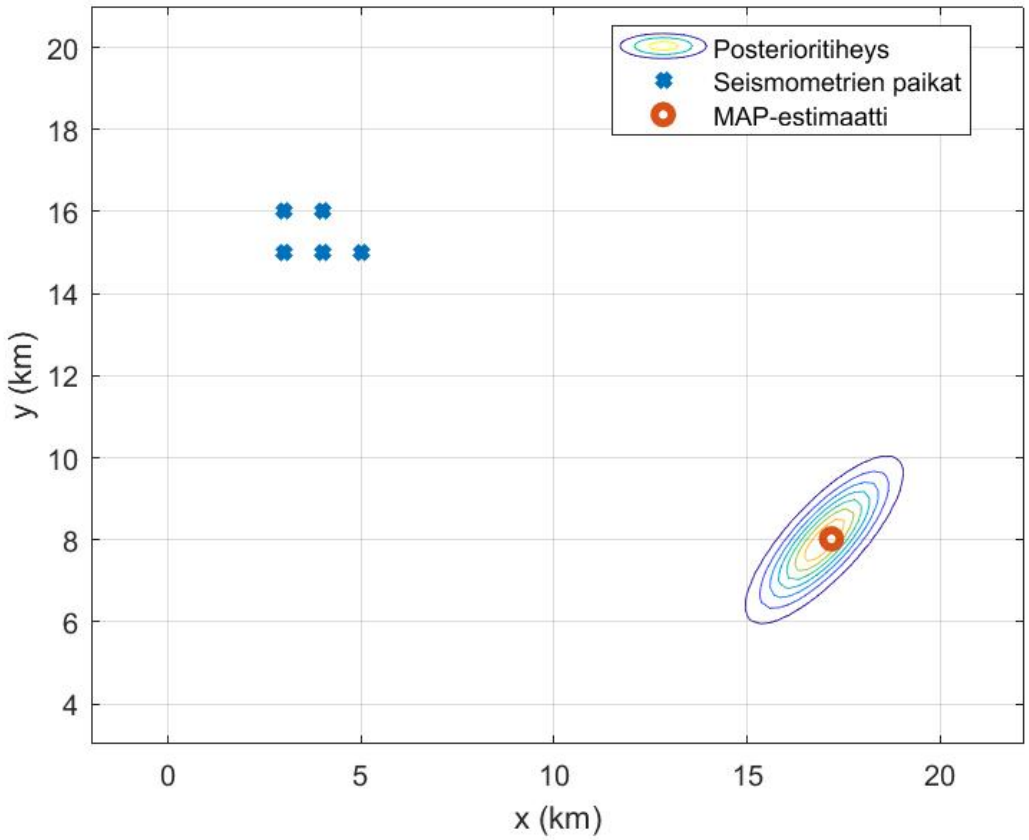


Kuva 1.3: Maanjäristyksen lähteen MAP-estimaatti sekä posterioritiheys, kun prioritietona on käytetty tehtävänannossa annettuja tietoja.

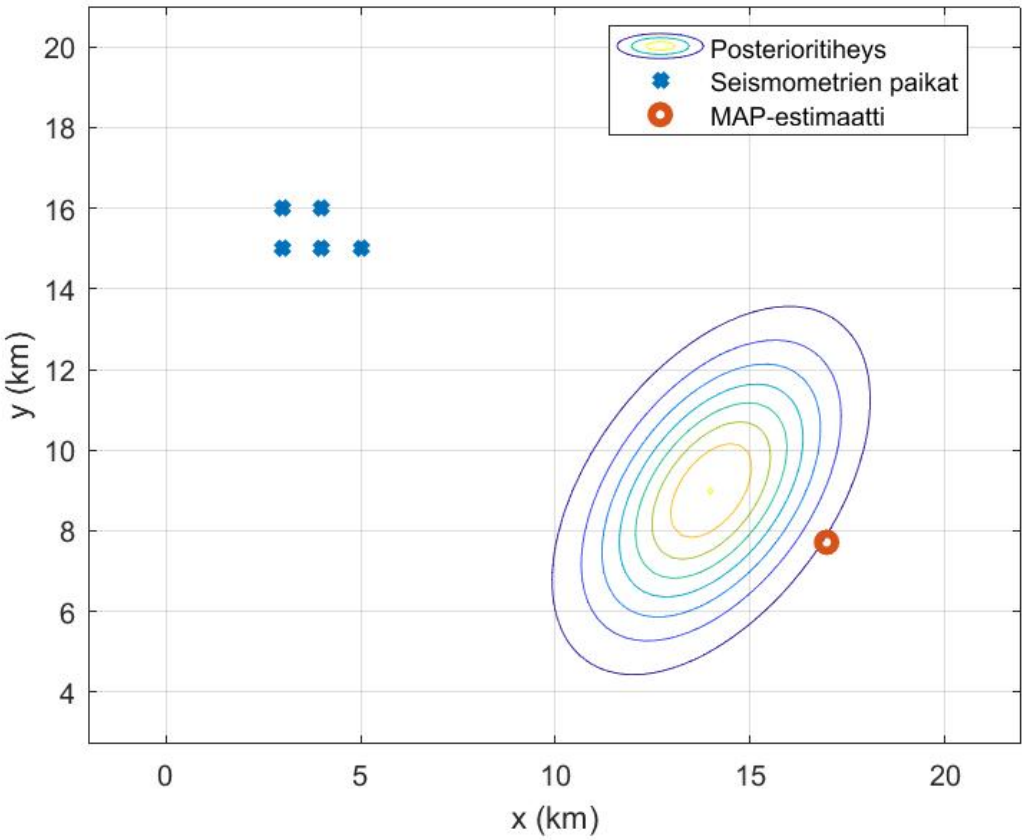
Kuvissa 1.4, 1.5 ja 1.6 vaihdeltiin mittauksien lukumääriä sekä prioritietoja. Kuvissa on esitetty posterioritiheys, estimaatissa käytettyjen seismisten mittausasemien paikat ja MAP-estimaatti maanjäristyksen lähteelle.



Kuva 1.4: Maanjäristyksen lähteen MAP-estimaatti neljällä mittauksella, prioriodotusarvolla $\eta_{\mathbf{s}} = [15 \;\; 7]^T$ sekä priorikovarianssilla $C_{\mathbf{s}} = [1 \;\; 0.7 \; ; \; 0.7 \;\; 2]$.



Kuva 1.5: Maanjäristyksen lähteen MAP-estimaatti viidellä mittauksella, prioriodotusarvolla $\eta_{\mathbf{s}} = [17 \;\; 8]^T$ sekä priorikovarianssilla $C_{\mathbf{s}} = [1 \;\; 0.8 \; ; \; 0.8 \;\; 1]$.



Kuva 1.6: Maanjäristyksen lähteen MAP-estimaatti viidellä mittauksella, prioriodotusarvolla $\eta_{\mathbf{s}} = [14 \;\; 9]$ sekä priorikovarianssilla $C_{\mathbf{s}} = [4 \;\; 2.2 \; ; \; 2.2 \;\; 5]$.

Luku 2

Lentokoneen paikan estimointi tutkadatasta

2.1 Yhteenveto

Tässä työssä lentokoneen liikettä estimoitiin Kalman-suotimen (KS) avulla käyttäen tutkasta saatuja mittauksia etäisyydelle ja kulmalle. Lentokoneen tila esitettiin parametrivektorina, jossa huomioitiin sekä sijainti että sen aikaderivaatat.

Systeemin liikemalli perustui Newtonin kinematiikkaan ja oletukseen tasaisesti kiihtyvästä liikkeestä tietyllä aikavälillä, minkä perusteella muodostettiin KS-algoritmissa vaaditut tilan siirtymämatriisi ja prosessikohinan siirtomatriisi. Lisäksi algoritmiin tarvittiin havaintomalli, joka mallinsi tutkadataa havaintomatriisin ja ennalta määriteltyjen virheiden perusteella.

KS-algoritmi toteutettiin MatLab-ympäristössä, ja sen avulla saatiin estimoitua lentokoneen paikka ja nopeus sekä napakoordinaateissa että karteesisessa koordinaatistossa. Suodin päivitti tilaa jokaisella mittaushetkellä yhdistäen ennustetun tilan ja mitatun tiedon.

Tuloksista havaittiin, että Kalman-suodin suoriutui hyvin lentokoneen liikeradan arvioinnissa erityisesti tehtävänannossa annettujen arvojen kanssa, mutta jos kohina-arvoja muutettiin, liikeradan estimaatti ei enää ollut yhtä luotettava. Jos systeemin prosessikohinaa lisättiin, KS-estimaatti vääristi lentokoneen etäisyyttä havainnoista. Vielä suuremmalla prosessikohinalla estimaatti keskittyi yksittäisiin mittauspisteisiin enemmän kuin toisiin saaden aikaan epärealistisia lentokuvioita. Prosessikohinan ollessa liian pieni estimaatti vääristi tuloksia jopa enemmän kuin liian suurella kohinalla. Tämä voi johtua siitä, että systeemi ei ole tasaisesti kiihtyvässä liikkeessä, jolloin prosessikohinan siirtomatriisin avulla malli pyrkii korjaamaan tästä aiheutuvaa virhettä ja täten jos kohina on liian pieni se estää korjauksen ja johtaa virheelliseen esti-

maattiin.

Prosessikohinan lisäksi tarkasteltiin myös havaintomallin kohinan vaikutusta estimaatteihin. Havaintomallin kohinan lisääminen vääristi lentokoneen etäisyyteen tutkasta, mutta KS-estimaatin kuvaaja säilyi tasaisena ja lentoreitti realistisena. Jos havaintomallin kohina valittiin pienemmäksi kuin tehtävänannossa, kulki KS-estimaatti lähempänä havaintopisteitä luoden jälleen epärealistisia lentoreittejä. Havaintomallin kohinan ollessa nolla KS-estimaatti kulki suoraan havaintopisteiden läpi.

Tehtävänannossa annettujen arvojen avulla lasketut nopeudet kulmalle ja etäisyydelle vaikuttivat järkeviltä. Virheet sijainnille ja kulmalle pysyivät alhaisina, ja laskettu keskineliövirhe osoitti hyvää estimointitarkkuutta. Etäisyyden keskineliövirhe oli 0.4968 m ja kulman 0.1626 rad. Virhekäyrien perusteella suodin reagoi mittauskohinaan vakaasti ja tuotti tasaisen ja realistisen liikeradan ennusteen.

Johtopäätöksenä voidaan todeta, että KS-algoritmi soveltuu hyvin dynaamisten systeemien tilojen estimointiin, kunhan käytettyjen mallien kohinat on määritelty oikein. Tämä edellyttää usein riittävää tietoa systeemin todellisesta kohinasta, jotta estimaatti pysyy tarkkana ja luotettavana.

2.2 Teoria

Tehtävässä lentokoneen liikettä mallinettaan parametrivektorin avulla, mikä on muotoa

$$x_t = (r_t, \dot{r}_t, \theta_t, \dot{\theta}_t)^T \tag{2.2.1}$$

missä r_t on etäisyys tutkan ja lentokoneen välillä, $\dot{r}_t$ on r_t:n aikaderivaatta eli nopeus, θ on tutkan kulma ja $\dot{\theta}$ kulmanopeus. Newtonin kinematiikan avulla parametrivektorin tueksi saadaan muodostettua evoluutiofunktion Kalman suodinta varten. Oletetaan etenemisliike tasaisesti kiihtyväksi aikavälillä [t, t + ΔT], jolloin lentokoneen liikettä voidaan kuvata rekursiivisesti alla olevien yhtälöiden avulla

$$\begin{cases} r_{t+1} = r_t + \dot{r}_t \Delta T + \frac{1}{2} a_{r,t} \Delta T^2, \\ \dot{r}_{t+1} = \dot{r}_t + a_{r,t} \Delta T. \end{cases}$$

ja

$$\begin{cases} \theta_{t+1} = \theta_t + \dot{\theta}_t \Delta T + \frac{1}{2} a_{\theta,t} \Delta T^2, \\ \dot{\theta}_{t+1} = \dot{\theta}_t + a_{\theta,t} \Delta T. \end{cases}$$

missä ΔT on aika kahden havainnon välillä, $a_{\theta,t}$ on kulmakiihtyvyys ja $a_{r,t}$ on kiihtyvyys. Valitsemalla kiihtyvyydet systeemin kohinan aiheuttamaksi virheeksi ω voidaan kyseiset yhtälöt ilmaista matriisimuotoisena evoluutiofunktiona

$$x_{t+1} = \begin{pmatrix} r_{t+1} \\ \dot{r}_{t+1} \\ \theta_{t+1} \\ \dot{\theta}_{t+1} \end{pmatrix} = \underbrace{\begin{pmatrix} 1 & \Delta T & 0 & 0 \\ 0 & 1 & 0 & 0 \\ 0 & 0 & 1 & \Delta T \\ 0 & 0 & 0 & 1 \end{pmatrix}}_{F_t} x_t + \underbrace{\begin{pmatrix} \frac{\Delta T^2}{2} & 0 \\ \Delta T & 0 \\ 0 & \frac{\Delta T^2}{2} \\ 0 & \Delta T \end{pmatrix}}_{G_t} \begin{pmatrix} \omega_{r,t} \\ \omega_{\theta,t} \end{pmatrix},$$

missä F_t on tilan siirtymämatriisi ja G_t on prosessikohinan siirtomatriisi. Lisäksi evoluutiomallille pätee

$$E\{\omega_t\} = 0 \text{ ja } C_{\omega_t} = \begin{bmatrix} \sigma^2_{\omega_{r,t}} & 0 \\ 0 & \sigma^2_{\omega_{\theta,t}} \end{bmatrix}$$

Jotta Kalman-suodin voidaan muodostaa, tarvitaan vielä havaintomalli, joka on muotoa

$$z_t = H_t x_t + v_t,$$

missä H_t on havaintomatriisi z_t on havainnot eli tutkasta saadut mittaukset, ja v_t on mittausvirhe. Havaintomallin osat voidaan esittää tarkemmin seuraavasti

$$z_t = \begin{bmatrix} \theta_t \\ r_t \end{bmatrix}, \quad H_t = \begin{bmatrix} 1 & 0 & 0 & 0 \\ 0 & 0 & 1 & 0 \end{bmatrix}, \quad E\{v_t\} = 0, \quad C_{v_t} = \begin{bmatrix} \sigma_v^2 & 0 \\ 0 & \sigma_v^2 \end{bmatrix}.$$

Lopulta käyttämällä evoluutio- ja havaintomallia voidaan luentomonisteen pohjalta johtaa Kalman-suodin -algoritmi, jonka avulla lentokoneen sijainti ja nopeus saadaan estimoitua ennustamalla systeemin tila ja korjaamalla sitä mittausten avulla. Kalman-suodin -algoritmi saadaan muotoon

$$C_{\tilde{x}_0} = C_{x_0},$$

missä $C_{\tilde{x}_0}$ on alkuarvaus x:n kovarianssille ja C_{x_0} on tilan alkuperäinen epävarmuus.

$$\hat{x}_0 = E\{x_0\},$$

missä $\hat{x}_0$ on tilan eli parametrivektorin alkuarvaus.

$$\hat{x}_{t|t-1} = F_{t-1}\hat{x}_{t-1},$$

missä $\hat{x}_{t|t-1}$ on tilan ennuste hetkellä t.

$$C_{\tilde{x}_{t|t-1}} = F_{t-1}C_{\tilde{x}_{t-1}}F_{t-1}^T + G_{t-1}C_{\omega_{t-1}}G_{t-1}^T,$$

missä $C_{\tilde{x}_{t|t-1}}$ on ennusteen kovarianssi ja $C_{\omega_{t-1}}$ on prosessikohinan kovarianssi.

$$K_t = C_{\tilde{x}_{t|t-1}}H_t^T\left(H_tC_{\tilde{x}_{t|t-1}}H_t^T + C_{v_t}\right)^{-1},$$

missä K_t on Kalmanin vahvistus ja C_{v_t} on mittauskohinan kovarianssi.

$$\hat{x}_t = \hat{x}_{t|t-1} + K_t(z_t - H_t\hat{x}_{t|t-1}),$$

missä $\hat{x}_t$ on tilan päivitetty arvio.

$$C_{\tilde{x}_t} = (I - K_tH_t)C_{\tilde{x}_{t|t-1}},$$

missä $C_{\tilde{x}_t}$ on päivitetyn tilan arviointivirheen kovarianssi ja I on yksikkömatriisi.
Kalman-suodin -algoritmilla saadaan jatkuvasti päivittyvä arvio $\hat{x}_t$ järjestelmän tilasta, tässä tapauksessa lentokoneen liikkeestä tutkadataan perustuen. Systeemin virhettä tutkitaan vertailemalla havaintojen ja estimaattien välistä erotusta ja laskemalla keskineliövirhe (RMSE, eng. root mean square error).

2.3 Tulokset

Lentokoneen reitin estimoimiseksi valittiin alkuarvaus tilan epävarmuudesta alla olevan matriisin mukaisesti

$$C_{\tilde{x}_0} = \begin{bmatrix} 0.3^2 & 0 & 0 & 0 \\ 0 & 0.3^2 & 0 & 0 \\ 0 & 0 & 0.3^2 & 0 \\ 0 & 0 & 0 & 0.3^2 \end{bmatrix},$$

ja prosessikohinan voimakkuus sekä mittauskohinan voimakkuus asetettiin arvoihin

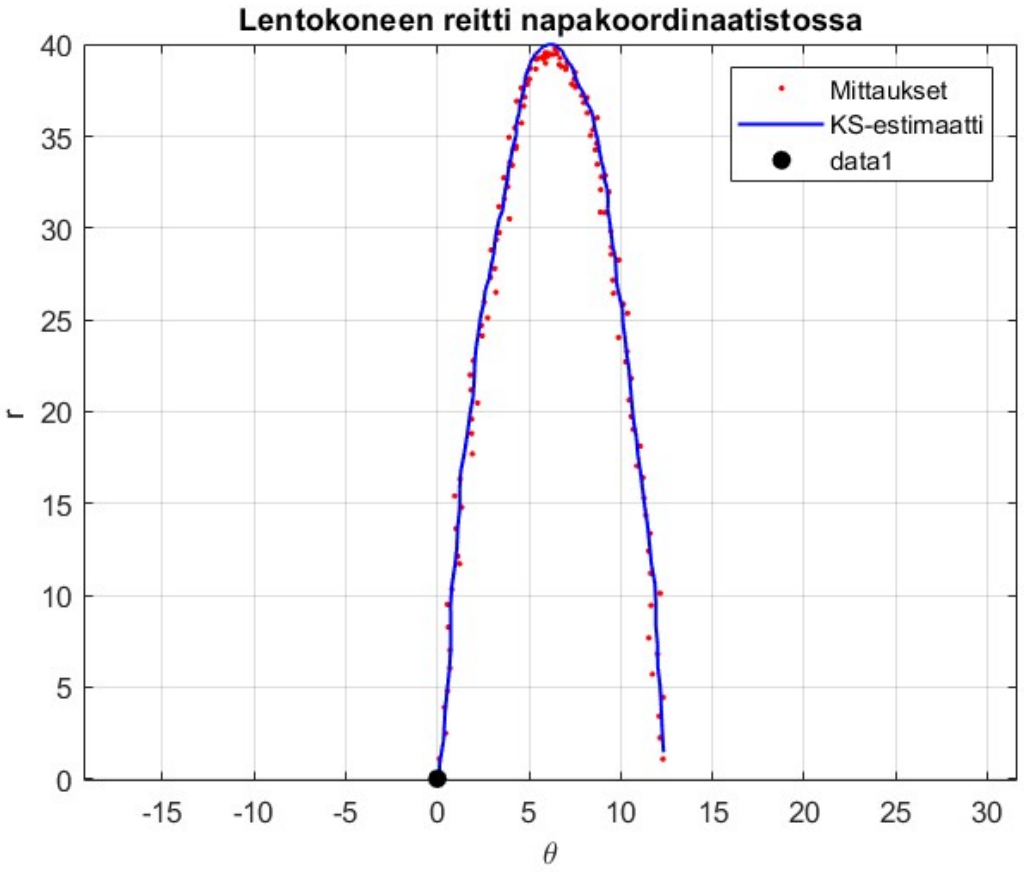
$$\sigma_\omega = 7 \cdot 10^{-3}, \quad \sigma_v = 0.2.$$

Lisäksi valittiin alustava parametrivektori, joka oli muotoa

$$\hat{x}_0 = (r_0, 0, \theta_0, 0)^T,$$

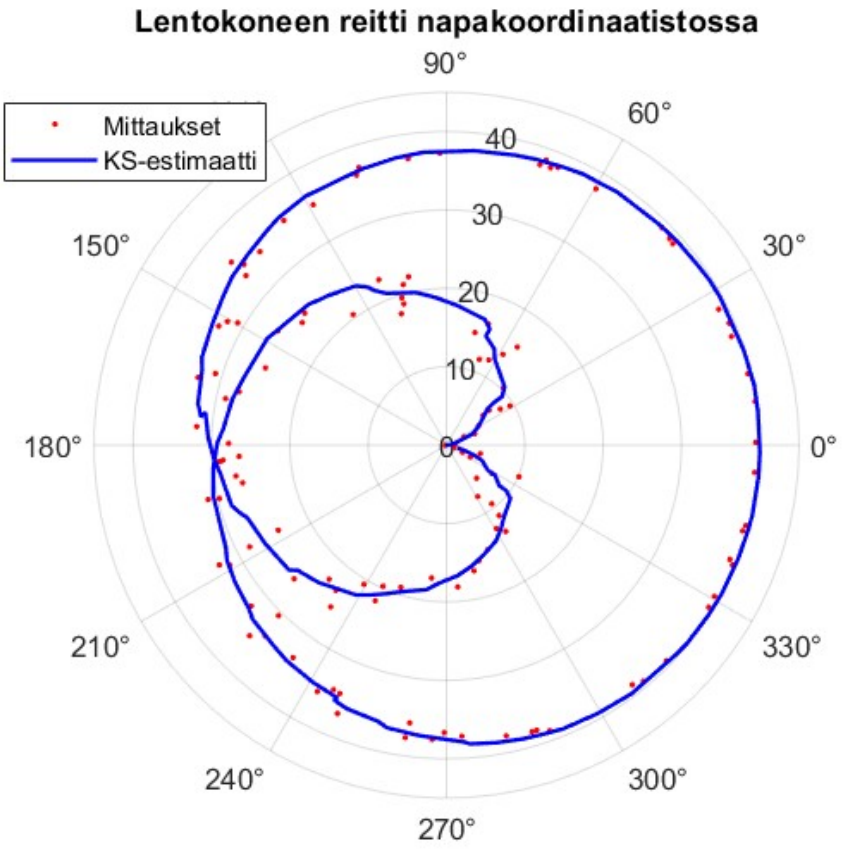
missä r_0 on havaintovektorin z_t ensimmäinen alkio etäisyydelle r ja θ_0 on ensimmäinen alkio kulmalle θ.

Tehtävänannossa vaadittu lentokoneen reitti saatiin ilmaistua napakoordinaatiston alkioilla karteesisessa kannassa Kuvassa 2.1

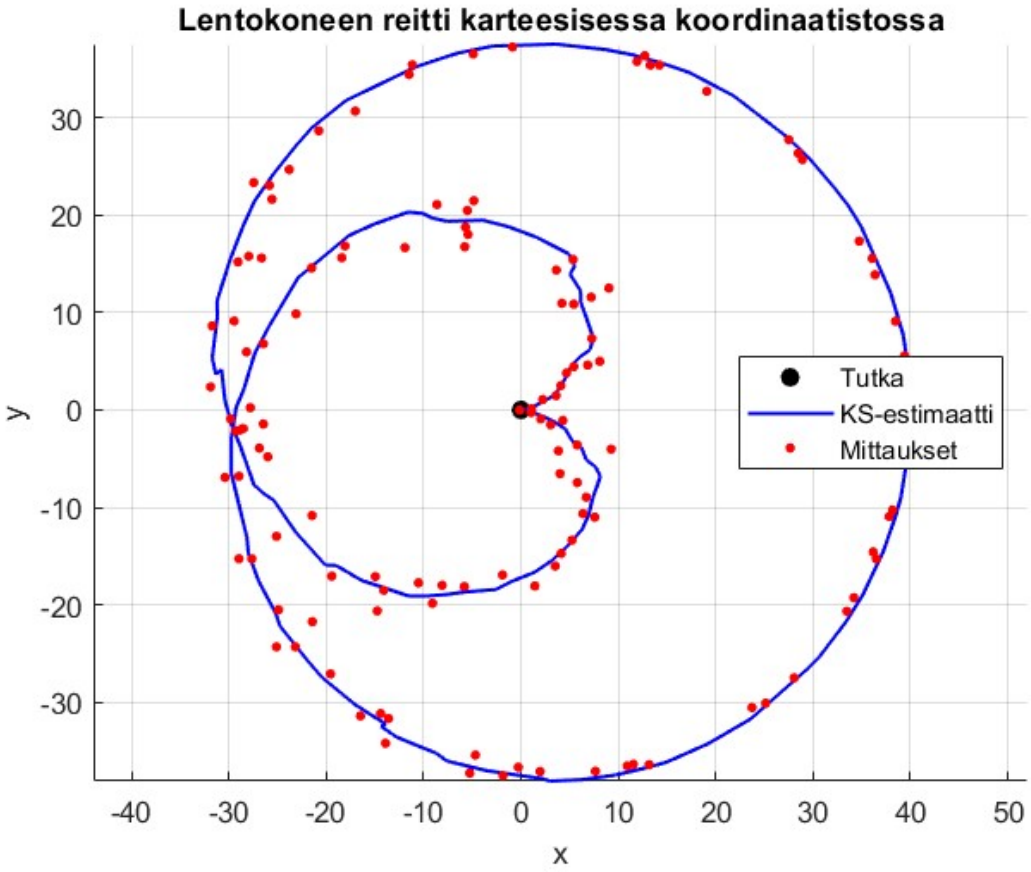


Kuva 2.1: Lentokoneen reitti karteesisessa kannassa napakoordinaatiston alkioilla r ja θ

Lentokoneen reittiä mallinnettiin myös napakoordinaatistossa napakoordinaatiston kannassa Kuvassa 2.2



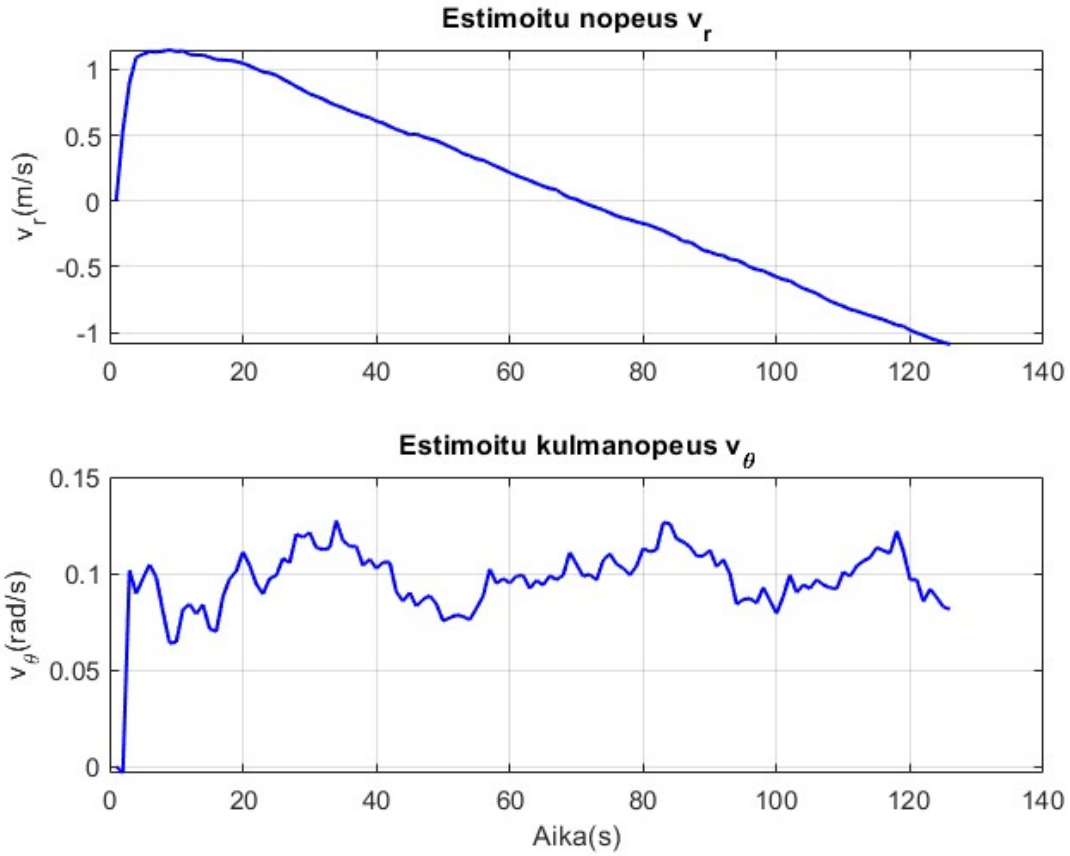
Kuva 2.2: Lentokoneen reitti napakoordinaatiston kannassa θ:n ja r:n suhteen.



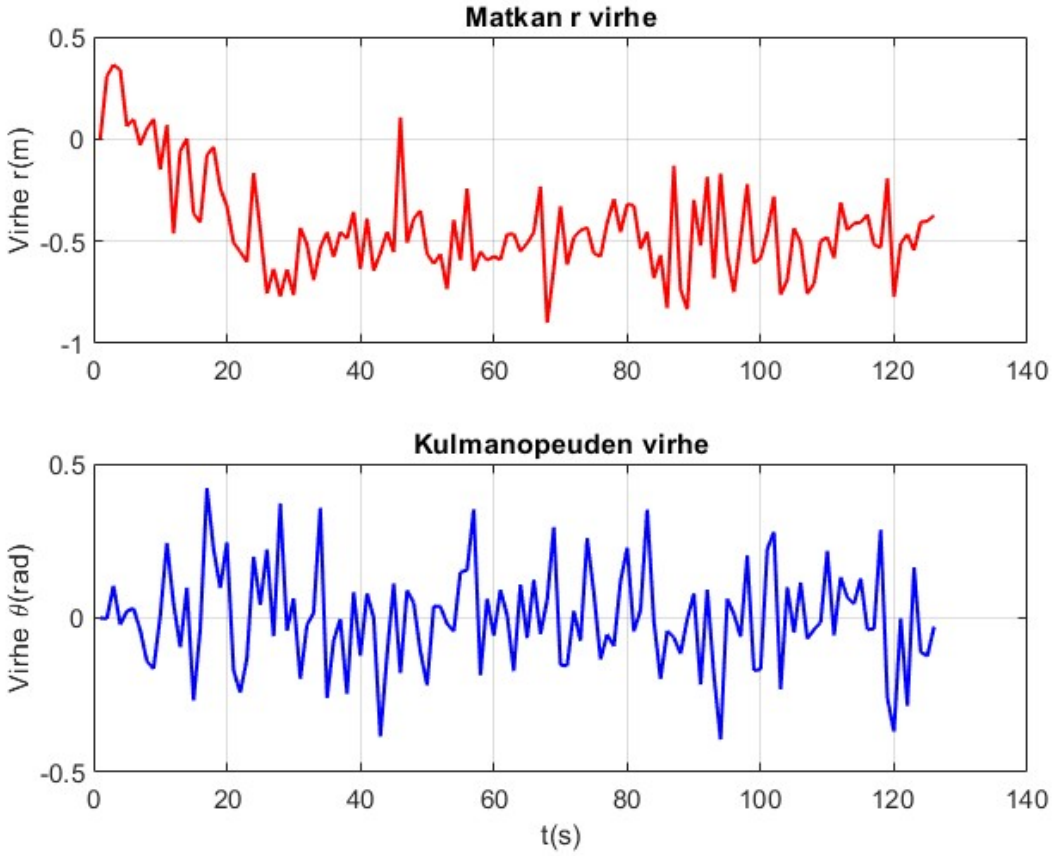
Kuva 2.3: Lentokoneen reitti karteesisessa (x,y)-koordinaatistossa.

Lentokoneen reitti selvitettiin myös karteesisessa koordinaatistossa Kuvassa 2.3. Kuvaaja saatiin muodostettua tekemällä koordinaatistomuunnos parametrivektorin alkioille.

Reitin lisäksi tuli estimoida parametrivektorin sisältämät nopeudet ja tehdä kuvaajat ajan suhteen niistä. Nämä kuvaajat on esitetty Kuvassa 2.4.



Kuva 2.4: Estimoidut nopeudet ajan suhteen.



Kuva 2.5: Virheet ajan suhteen.

Viimeiseksi selvitettiin Parametrien r ja θ virheet ajan suhteen ja laskettiin RMSE. Virheet ajan suhteen on esitetty Kuvassa 2.5 ja parametrien RMSE-arvot Taulukossa 2.1

Taulukko 2.1: Kalman-suotimen RMS-virheet etäisyydelle ja kulmalle.

Suure	**RMS-virhe**	**Yksikkö**
r	0.4968	m
θ	0.1626	rad