Tomografiatyö

Samu Honkakoski, Opnro: 2311628

Työ tehty: 8.12.2023, raportin 1. versio palautettu: 26.1.2024, raportin 2. versio palautettu: 29.2.2024, raportin 3. versio palautettu 24.3.2024

1 Tiivistelmä

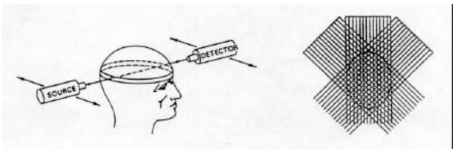
Työn tarkoituksena oli tutustua tomografiamenetelmään, jonka avulla lääketieteellisessä tutkimuksessa arvioidaan esimerkiksi luiden akuutteja vaurioita. Projektissa oli tehtävä-nä selvittää, minkälainen kuvio on muodostettu puupalikoista muovisen laatikon sisälle, kun välineinä oli gammasäteilylähde, kvanttimääriä mittaava anturi sekä tietokone ja tietokoneohjelmisto Matlab. Laskennallisina menetelminä toimi PNS-estimointi sekä Tikhonov-regularisaatio. Lopputuloksena saatiin selvitettyä puupalikoiden muodostama kuvio, kun muovikuoren vaikutus säteilyn vaimenemiseen otettiin huomioon. Lisäksi saatiin lisää tietoa siitä, miten regularisointimenetelmiä kannattaa hyödyntää ja missä tilanteessa.

2 Johdanto

2.1 Tomografiamenetelmä

Tomografiakuvantaminen on hyödyllinen laskennallinen työkalu, jossa kuvataan haluttua kohdetta eri suunnista ja kulmista. Tästä datasta saadaan muodostettua kuva, mistä kohde koostuu. Tomografiaa voidaan siis soveltaa kohteen 3-ulotteiseen mallinnukseen.

Tomografiakuvantamisessa kuvattava kohde asetetaan säteilylähteen (lääketieteessä röntgensäteilyä, tässä työssä gammasäteilyä) ja säteilyn mittaamiseen tarkoitetun anturin väliin. Näiden avulla voidaan mitata kohteen eri osien absorbtiokykyä säteilyn intensiteetin avulla (Kuva 1). Näin saadaan muodostettua kuvannettavalle kohteelle matemaattinen malli, jonka avulla kuva muodostetaan. Seuraavassa osiossa esitellään tomografiamenetelmän sovelluskohde lääketieteessä.



(a) (b)

Kuva 1: Tomografiamenetelmän periaate. Kuva otettu Tomografiatyön ohjeesta [2].

2.1.1 Tomografian soveltaminen lääketieteessä

Lääketieteessä CT-kuvantamista (eng. Computer Tomography) hyödynnetään röntgenkuvantamisessa sekä magneettikuvantamisessa. Kun tavallisesta 2-ulotteisesta röntgenkuvasta ei saada tarvittavaa dataa, siirrytään usein CT-kuvantamisen keinoihin. Esimerkiksi luuvaurion tunnistaminen hankalasta kuvattavasta paikasta, kuten nivelten seudulta, on helpompi tunnistaa tomografiakuvantamisen avulla [1].

Magneettikuvantamisessa (MRI, Magnetic Resonance Imaging) hyödynnetään samankaltaista tekniikkaa, mutta siinä muodostetaan magneettikenttiä kuvattavan kohteen ympäristöön. Magneettikuvantaminen on hyödyllisempi kudosten tutkimiseen, jotka sisältävät paljon rasvaa [3].

2.1.2 Tomografiatyö

Tässä projektityössä säteilytettiin gammasäteilyllä muovilaatikossa olevaa puupalikkamuodostelmaa 178 eri kohdasta ja eri kulmilla. Mittausten avulla muodostettiin kuva puupalasten paikoista laskennallisilla menetelmillä. Työn laskennallisessa osuudessa hyödynnettiin lineaarista PNS-estimointia, kuntoisuuslukua sekä Tikhonov-regularisaatiota. Laskennallisen osuuden teoria esitellään *Teoria* -osiossa.

3 Teoria

Projektityössä tarvittiin laskennallisten mallien teorioita mittausdatan käsittelyyn. Tässä osiossa perehdytään tarkemmin työssä tarvittuihin matemaattisiin menetelmiin.

3.1 Säteilyn vaimenemislaki

Säteilyn vaimenemislain yksinkertaisin muoto, missä vaimentava väliaine on homogeeninen, on muotoa

$$I = I_0 e^{-\mu x}, \tag{1}$$

missä I on säteilyn intensiteetti väliaineen läpäisyn jälkeen, I_0 on säteilyn intensiteetti alussa, μ on väliaineen vaimenemiskerroin, joka on yleensä välillä $\mu \in]0, 1[$. Yhtälön x on säteilyn kulkema matka väliaineessa.

Tämä kokeellinen tulos voidaan yleistää n kappaleelle väliaineita, jolloin yhtälö saa muodon

$$I = I_0 e^{-\sum_{i=1}^{n} \mu_i x_i}, \tag{2}$$

josta saadaan data-analyysiin sopivampi muoto

$$\ln \frac{I}{I_0} = -\sum_{i=1}^{n} \mu_i x_i. \tag{3}$$

Kun mittauksia on useampi, voidaan yhtälön (3) avulla kirjoittaa lineaarinen systeemi

$$\begin{bmatrix} \ln \frac{I_1}{I_0} \\ \ln \frac{I_2}{I_0} \\ \vdots \\ \ln \frac{I_m}{I_0} \end{bmatrix} = \begin{bmatrix} x_{11} & x_{12} & \dots & x_{1n} \\ x_{21} & x_{22} & \dots & x_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ x_{m1} & x_{m2} & \dots & x_{mn} \end{bmatrix} \begin{bmatrix} \mu_1 \\ \mu_2 \\ \vdots \\ \mu_n \end{bmatrix}, \tag{4}$$

missä lineaarisen systeemin kerroinmatriisi on dimensioltaan $m \times n$. Lineaariselle systeemille (4) voidaan muodostaa PNS-estimaatti.

3.2 Lineaarinen PNS-menetelmä

Tässä osiossa käsitellään lineaarisia systeemejä. Alkuasetelmana on systeemi

$$A\mathbf{x} = \mathbf{b}, \tag{5}$$

missä $A \in \mathbf{R}^{n\times n}$ on säännöllinen, $\mathbf{x} \in \mathbf{R}^n$ on selvitettävät parametrit ja $\mathbf{b} \in \mathbf{R}^n$ on mittausdata. Tällaisesta systeemistä vektori $\mathbf{x}$ on helppo selvittää kertomalla molempia puolia matriisin A käänteismatriisilla, merkitään sitä A^{-1}. Saadaan tästä

$$\mathbf{x} = A^{-1}\mathbf{b}. \tag{6}$$

Tämä tilanne ei ole kuitenkaan yleinen tilanne. Esimerkiksi tässä projektissa alkuasetelman havaintovektori on $H^{178\times 64}$, joka ei ole säännöllinen, sillä kyseinen matriisi ei ole neliömatriisi. Tällöin lineaarinen PNS-menetelmä on hyödyllinen. PNS-menetelmä eli pienimmän neliösumman menetelmä estimoi parametrejä, jotka ovat tässä tapauksessa vokselien vaimennuskertoimia. Lineaarinen PNS on muotoa

$$\hat{\mathbf{x}} = (H^T H)^{-1} H^T \mathbf{b}, \tag{7}$$

missä $\hat{\mathbf{x}}$ on estimoitavat parametrit, H on havaintomatriisi ja $\mathbf{b}$ on mittausdata.

3.3 Operaattorinormi ja kuntoisuusluku

3.3.1 Operaattorinormin johto

Operaattorinormia voidaan hyödyntää matriisin kuntoisuuden määrittämisessä. Matriisin kuntoisuus taas kertoo, kuinka häiriöaltis ilmiön matemaattinen malli on. Johdetaan eräs operaattorinormi, kun eräs operaattorinormin määritelmä on muotoa

$$\|L\| = \sup_{x\in\mathbf{R}^n;\|\mathbf{x}\|=1} \|Lx\|_{\mathbf{R}^m}. \tag{8}$$

Eräs operaattorinormi voidaan johtaa hyödyntämällä tätä määritelmää. Koska havaintomatriisi H ei ole neliömatriisi, on kuntoisuusluku muodostettava matriisille $A := H^T H$. Tällöin matriisi A on symmetrinen. Symmetrinen matriisi on säännöllinen, jos ja vain jos sen kaikki ominaisarvot $\lambda_i \neq 0$. Saadaan

$$\|Ax\|^2 = \langle Ax, Ax\rangle = (A^T x^T)Ax = x^T A^T Ax.$$

Koska Matriisi A on symmetrinen, eli $A^T = A$, voidaan kirjoittaa

$$x^T A^T Ax = x^T AAx = x^T A^2 x$$

Voidaan kirjoittaa vektori x lineaarikombinaationa

$$x = \sum_{i=1}^{n} a_i v_i,$$

missä a_i, $i = 1, 2, ..., n$ ovat lineaarikombinaation skaalauskertoimia, sekä v_i vektoriavaruuden $\mathbf{R}^n$ normaalikannan vektorit. Tällöin voidaan kirjoittaa lauseke muotoon

$$\|A\mathbf{x}\| = \sqrt{(\sum_{i=1}^{n} a_i v_i)^T A^2 \sum_{i=1}^{n} a_i v_i} = \sqrt{\sum_{i=1}^{n} a_i (v_i)^T A^2 \sum_{i=1}^{n} a_i v_i}$$

Matriisi A voidaan viedä summien sisälle, sillä summissa käsitellään vain matriisin diagonaalialkioita. Symmetrinen matriisi voidaan kirjoittaa hajotelmana, jonka keskimmäisen matriisin diagonaalialkiot ovat ominaisarvoja λ_i. Saadaan

$$\sqrt{\sum_{i=1}^{n} a_i (v_i)^T A^2 \sum_{i=1}^{n} a_i v_i} = \sqrt{\sum_{i=1}^{n} a_i (v_i) \sum_{i=1}^{n} a_i \lambda_i^2 v_i}$$

$$= \sqrt{\sum_{i=1}^{n} a_i^2 \lambda_i^2 (v_i)^T v_i}.$$

Koska v_i ovat normaalikannan vektoreita, on pistetulo $(v_i)^T v_i = 1$. Siispä saadaan

$$\sqrt{\sum_{i=1}^{n} a_i^2 \lambda_i^2 (v_i)^T v_i} = \sqrt{\sum_{i=1}^{n} a_i^2 \lambda_i^2}$$

$$\leq \sqrt{\sum_{i=1}^{n} a_i^2 \lambda_{max}^2} = \sqrt{\sum_{i=1}^{n} a_i^2} \lambda_{max}$$

Operaattorinormin määritelmän nojalla vektori $x \in \mathbf{R}^n; \|x\| = 1$, joten $\sum_{i=1}^{n} a_i = 1$. Tällöin

$$\sqrt{\sum_{i=1}^{n} a_i^2} \lambda_{max} = \lambda_{max}.$$

Tehdään valinta, että $\mathbf{x}$ on maksimi ominaisvektori $\max(\mathbf{v})$ symmetriselle matriisille A. Tällöin saadaan

$$\begin{aligned} \sup_{x \in \mathbf{R}^n; \|x\|=1} \|Ax\| &\geq \sqrt{\max(v^T) A^T A \max(v)} \\ &= \sqrt{\max(v^T) A^2 \max(v)} \\ &= \sqrt{\max(v^T) \lambda^2 \max(v)} \\ &= \lambda_{max} \end{aligned}$$

Supremumin määritelmän nojalla saadaan

$$\sup_{\mathbf{x} \in \mathbf{R}^n; \|x\|=1} \|Ax\| = \|A\|_2 = \lambda_{max}. \tag{9}$$

3.3.2 Kuntoisuusluku

Kuntoisuusluku saadaan epäyhtälöstä

$$\frac{\|x_1 - x_2\|}{\|x_1\|} \leq \|A\|\|A^{-1}\|\frac{\|b_1 - b_2\|}{\|b_1\|},$$

missä $x_1, x_2 \in \mathbf{R}^n$ ovat selvitettäviä parametrejä ja $b_1, b_2 \in \mathbf{R}^m$ ovat eri mittausten mittausdata. Epäyhtälön oikean puolen verrannollisuuskerrointa $\|A\|\|A^{-1}\|$ kutsutaan kuntoisuusluvuksi, jota merkitään

$$cond(A) = \|A\|\|A^{-1}\| = \max \lambda_A \cdot \max \lambda_{A^{-1}}. \tag{10}$$

Matriisin A käänteismatriisin A^{-1} ominaisarvot ovat muotoa $\frac{1}{\lambda_A}$, jolloin

$$\max \lambda_{A^{-1}} = \frac{1}{\min \lambda_A}.$$

Tällöin saadaan siis kuntoisuusluvuksi

$$cond(A) = \frac{\max \lambda_A}{\min \lambda_A} \tag{11}$$

Matriisi on hyväkuntoinen, jos sen kuntoisuuskuku on 1 tai sitä lähellä. Jos kuntoisuusluku $cond(A) >> 1$, niin matriisin kunto on huono, ja siitä muodostettu PNS-estimaatti on herkkä virheille. Tällaisille matriiseille voidaan tehdä pieniä korjauksia, jotka muuttavat matriisin kuntoisuutta parempaan.

3.4 Tikhonov-regularisaatio

Tikhonov-regularisaatiolla voidaan parantaa matriisin kuntoa, jotta se olisi käyttökelpoisempi lineaarisia systeemejä estimoidessa. Tikhonov-regularisaatiossa matriisiin $H^T H$ lisätään joko skaalattu yksikkömatriisi αI tai muu matriisi, jolloin matriisin kunto paranee. Työssä hyödynnettiin myös 1. differenssimatriisia. Tikhonov-regularisaatioyhtälö on muotoa

$$H_{reg} = H^T H + T, \tag{12}$$

missä H_{reg} on regularisoitu matriisi ja T on regularisaatiomatriisi. Työn kaksi regularisointimatriisia ovat

$$H_{reg1} = H^T H + \alpha I,$$

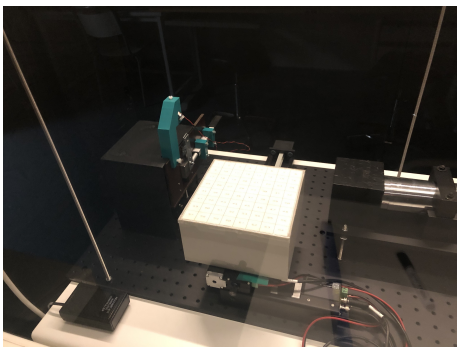
missä $\alpha \in \mathbf{R}$ on yksikkömatriisin skalaarikerroin sekä

$$H_{reg2} = H^T H + \alpha(L^T L),$$

missä L on 1. differenssimatriisi.

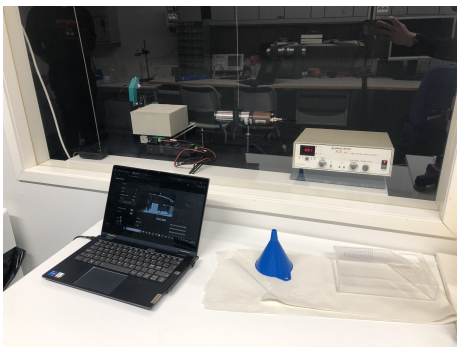
4 Materiaalit ja menetelmät

Työssä hyödynnettiin säteilylähdettä ja sen säteilyä mittaavaa anturia (Kuvassa 2). Säteilylähde emittoi gammasäteilyä, jota anturi mittasi kvanttimäärinä. Tämä ei ole ongelma, sillä kvanttimäärät käyttäytyvät yhtälön (3) logaritmin sisällä samalla tavalla kuin intensiteetti. Tämä perustuu Beer-Lambertin lakiin, jonka nojalla gammakvanttimäärät ovat verrannollisia gammakvantin energiaan, ja energia on verrannollinen intensiteettiin. Gammakvanttien määrä on tässä työssä riittävän pätevä suure, sillä tehtävänä on selvittää puupalikoiden paikat muovisen laatikon sisällä.



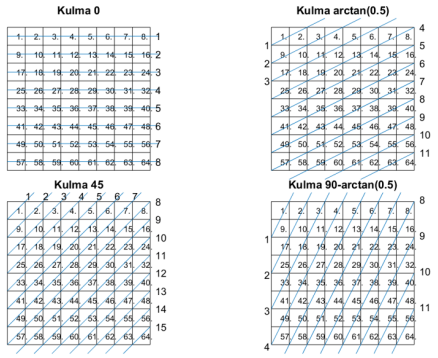
Kuva 2: Säteilylähde vasemmalla ja kvanttimäärien mittausanturi oikealla. Keskellä näkyvä laatikko on tutkittava kohde.

Mittausdatan tallentaminen tapahtui tietokoneella verkkoselaimeen upotetulla ohjelmalla langattomasti (Kuvassa 3). Lopullinen mittausdata tallennettiin Excel-tiedostoon sekä kuvatiedostona.

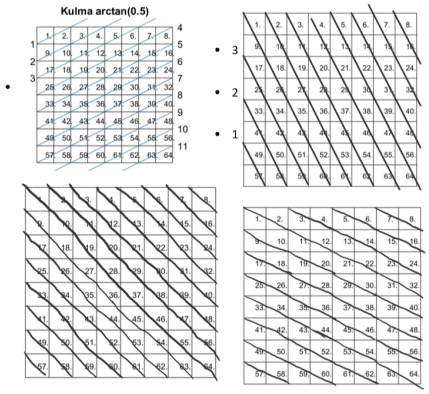


Kuva 3: Koko mittausasetelma, missä tietokoneella on verkkoselaimessa mittausten suorittamiseen tarkoitettu ohjelma.

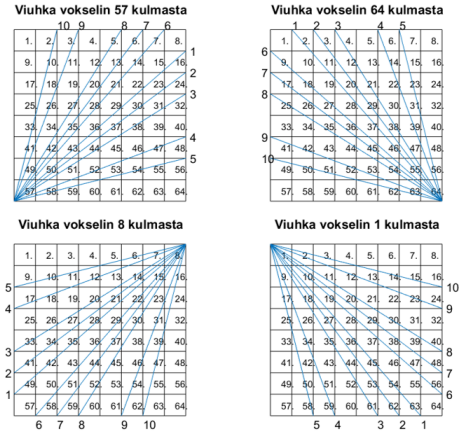
Mittaussarjat suoritettiin siten, että mitattiin ensin samansuuntaisesti eri kulmilla laatikkoon nähden (Kuvat 4 ja 5). Tämän jälkeen mitattiin viuhkamittauksia, jossa



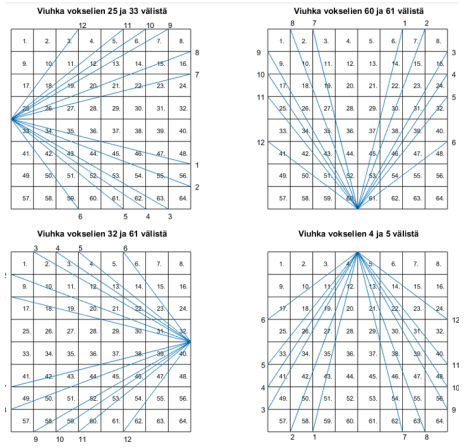
Kuva 4: Ensimmäiset neljä mittaussarjaa. Ruudukko esittää laatikkoa, jonka sisällä puupalikat olivat. Säteilymittaukset ovat eri kulmilla laatikkoon nähden. Kuva on otettu Mittaussarjat-liitteestä.



Kuva 5: Viimeiset mittaussarjat suorista mittauksista. Kuva on otettu Mittaussarjat-liitteestä.



Kuva 6: Viuhkamittaukset laatikon kulmista. Kuva on otettu Mittaussarjat-liitteestä.



Kuva 7: Viuhkamittaukset laatikon keskiosista. Kuva on otetu Mittaussarjat-liitteestä.

säteilyn kulmaa muutettiin jokaisella erillisellä mittauksella (Kuvat 6 ja 7). Kaikista mittauksista muodostettiin havaintomatriisi, jossa oli esitettynä säteilyn kulkema matka eri vokseleissa. Tämän matriisin, sekä mitattuilla gammafotonien määrillä voidaan yhtälön (4) sekä lineaarisen PNS-menetelmän (yhtälö (7)) avulla saadaan estimoitua työssä vaaditut parametrit, eli jokaisen vokselin vaimennuskertoimet.

Mittausten käsittelyssä selvitettiin, että vaikuttaako muovikuoren huomioiminen mittauksissa lopputulokseen, joka esitetään kuvana, joka esittää vaimennuskerroinjakaumaa laatikon sisällä.

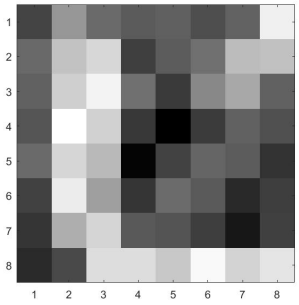
Datan käsittelyssä hyödynnettiin MATLAB-ohjelmistoa. MATLAB-ohjelmistolla muodostettiin matriisit PNS-estimaatteihin sekä Tikhonov-regularisaatioon, ja tehtiin edellä mainitut operaatiot. Huonokuntoisen matriisin koko oli 90×65 ja hyväkuntoisen matriisin koko oli 91×65. Mittausdatan koossa on huomioitu muovikuori yhdellä lisäsarakkeella.

5 Tulokset

Muodostetuissa vaimennuskerroinjakaumissa vaaleammat osat kuvaavat suurempaa vaimennuskerrointa, kun taas tummemmat kuvaavat pienempää vaimennuskerrointa. Mittausdatasta saatiin PNS-estimaattia sekä Tikhonov-regularisaatiota hyödyntämällä seuraavanlaisia tuloksia. PNS-estimaateissa on huomioitu muovilaatikko, mutta kuvia muodostaessa muovilaatikon vaimenemiskerroin on poistettu, sillä sen vaikutus muihin vaimennuskertoimiin on otettu huomioon jo PNS-estimaateissa. Muovikuoren vaimennuskertoimeksi saatiin

$$\mu_{kuori} = 0,09085.$$

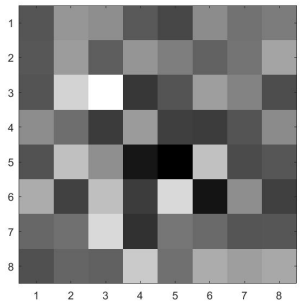
Koska muovikuoren vaimennuskerroin on pieni, on muovikuoren vaikutus on hyvin pieni kokonaisuuteen.



Kuva 8: Koko mittausdatasta muodostettu vaimennuskerroinjakauma. Jakauma on muodostettu lineaarisella PNS-menetelmällä.

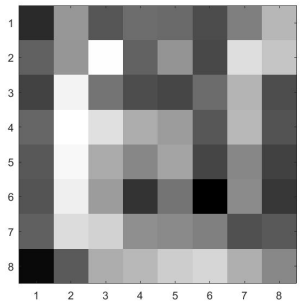
Koko mittausdatasta muodostetusta vaimennuskerroinjakaumasta (Kuva 8) havai-

taan L-muotoinen vaalea osa, joka menee vasemmasta reunasta alareunaan. Lisäksi oikeassa yläkulmassa on vaalea osa. Koko mittausdatasta muodostetun matriisin kuntoisuusluvuksi saatiin $cond(H) = 50,9$.



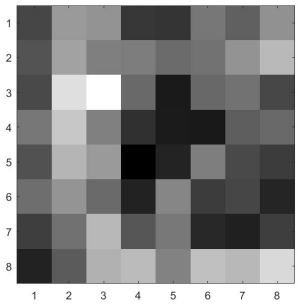
Kuva 9: Huonokuntoisimmasta mittausdatan osasta muodostettu vaimennuskerroinjakauma. Huonokuntoinen matriisi saatiin suorien mittauksien datasta. Jakauma on muodostettu lineaarisella PNS-menetelmällä.

Huonokuntoisen matriisin vaimennuskerroinjakaumassa (Kuva 9) on vasemman reunan keskiosissa vaaleampaa, sekä yksittäisiä vaaleita täpliä jakauman keskiosissa. Jakauman keskiosissa on todella tumma osio. Muuten jakauma on harmaan värinen. Huonokuntoisen mittausdatan osan kuntoisuusluvuksi saatiin $cond(H_{huono}) = 1,2 \cdot 10^{17}$.



Kuva 10: Hyväkuntoisimman mittausdatan osasta muodostettu vaimennuskerroinjakauma. Hyväkuntoinen matriisi saatiin käyttämällä viuhkamittauksien mittausdataa. Jakauma on muodostettu lineaarisella PNS-menetelmällä.

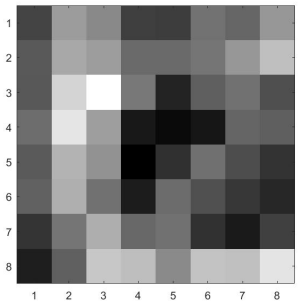
Hyväkuntoisen matriisin vaimennuskerroinjakaumassa (Kuva 10) on samankaltaisia piirteitä, kun koko mittausdatan jakaumassa, mutta on huomattavasti epätarkempi. L-kuvio sijoittuu vasemmasta laidasta alalaitaan, ja oikeassa yläkulmassa on vaaleaa.



Kuva 11: Yksikkömatriisin avulla Tikhonov-regularisoidun huonokuntoisen matriisin vaimennuskerroinjakauma. Yksikkömatriisin skalaarikerroin on $\alpha = 0,5$.

Hyväkuntoisen mittausdatan osan kuntoisuusluvuksi saatiin $cond(H_{hyva}) = 1,348 \cdot 10^4$.

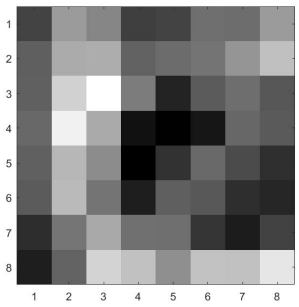
Yksikkömatriisin (skaalauskerroin $\alpha = 0,5$) avulla regularisoidun huonokuntoisen matriisin vaimennuskerroinjakaumassa (Kuva 11) on hieman vaaleammalla harmaalla sama L-kuvio, kun hyväkuntoisemmista matriiseista muodostetuissa jakaumissa. Se ei ole kuitenkaan yhtä selkeä. Lisäksi keskellä on hyvin tumma osa.



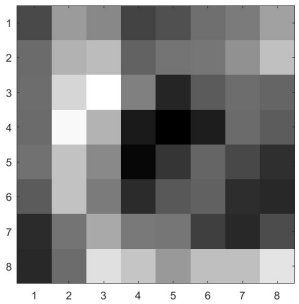
Kuva 12: Yksikkömatriisin avulla Tikhonov-regularisoidun huonokuntoisen matriisin vaimennuskerroinjakauma. Yksikkömatriisin skalaarikerroin on $\alpha = 1,5$.

Yksikkömatriisin (skaalauskerroin $\alpha = 1,5$) avulla regularisoidun huonokuntoisen matriisin vaimennuskerroinjakaumassa (Kuva 12) näkyy hieman selkeämmin vaalea L-kuvio, kun skaalauskertoimella $\alpha = 0,5$. L-kuvio vaalenee, kun kerrointa α kasvatetaan (Kuvat 13 ja 14).

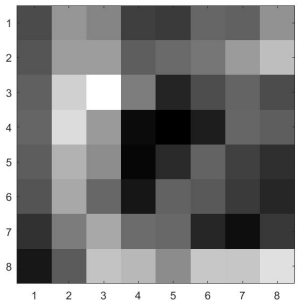
1. differenssimatriisin avulla regularisoidun huonokuntoisen matriisin vaimennuskerroinjakaumissa L-kuvio selkeytyy, mutta skalaarikertoimen α vaikutus on hyvin pieni. Vaimennuskerroin jakaumat näyttävät lähes identtisiltä (Kuvat 16, 17, 18 ja 19).



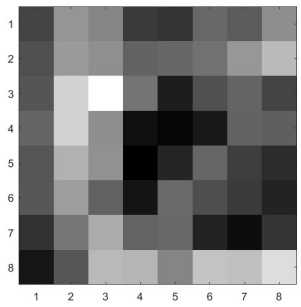
Kuva 13: Yksikkömatriisin avulla Tikhonov-regularisoidun huonokuntoisen matriisin vaimennuskerroinjakauma. Yksikkömatriisin skalaarikerroin on $\alpha = 3,5$.



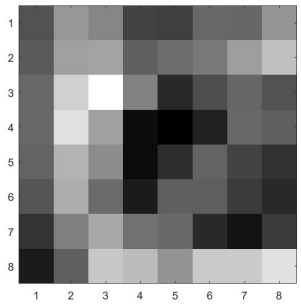
Kuva 14: Yksikkömatriisin avulla Tikhonov-regularisoidun huonokuntoisen matriisin vaimennuskerroinjakauma. Yksikkömatriisin skalaarikerroin on $\alpha = 10$.



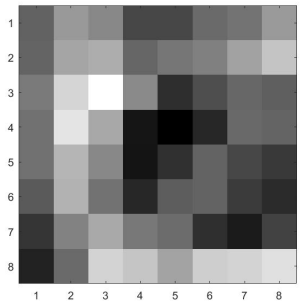
Kuva 15: 1. differenssimatriisin avulla Tikhonov-regularisoidun huonokuntoisen matriisin vaimennuskerroinjakauma. 1. differenssimatriisin skalaarikerroin on $\alpha = 1$.



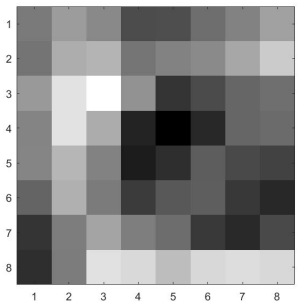
Kuva 16: 1. differenssimatriisin avulla regularisoitu huonokuntoisen matriisin mittausdata, kun 1. differenssimatriisin skalaarikerroin on $\alpha = 0,5$.



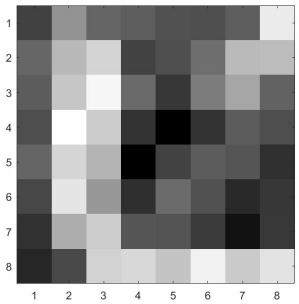
Kuva 17: 1. differenssimatriisin avulla regularisoitu huonokuntoisen matriisin vaimennuskerroinjakauma. 1. differenssimatriisin skalaarikerroin on $\alpha = 1,5$.



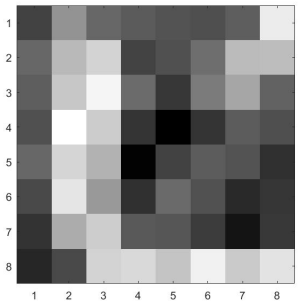
Kuva 18: 1. differenssimatriisin avulla Tikhonov-regularisoidun huonokuntoisen matriisin vaimennuskerroinjakauma. 1. differenssimatriisin skalaarikerroin on $\alpha = 3,5$.



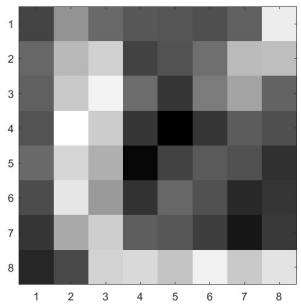
Kuva 19: 1. differenssimatriisin avulla Tikhonov-regularisoidun huonokuntoisen matriisin vaimennuskerroinjakauma. 1. differenssimatriisin skalaarikerroin on $\alpha = 10$.



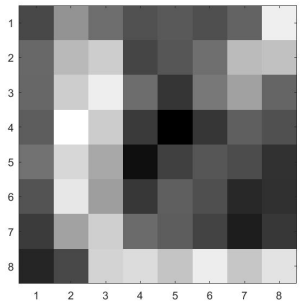
Kuva 20: Yksikkömatriisin avulla Tikhonov-regularisoidun hyväkuntoisen matriisin vaimennuskerroinjakauma. Yksikkömatriisin skalaarikerroin on $\alpha = 0,5$.



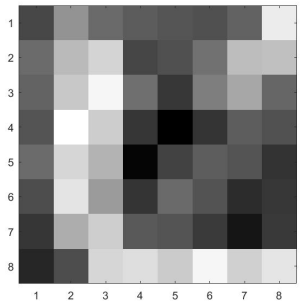
Kuva 21: Yksikkömatriisin avulla Tikhonov-regularisoidun hyväkuntoisen matriisin vaimennuskerroinjakauma. Yksikkömatriisin skalaarikerroin on $\alpha = 1,5$.



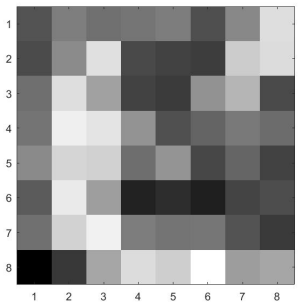
Kuva 22: Yksikkömatriisin avulla Tikhonov-regularisoidun hyväkuntoisen matriisin vaimennuskerroinjakauma. Yksikkömatriisin skalaarikerroin on $\alpha = 3,5$.



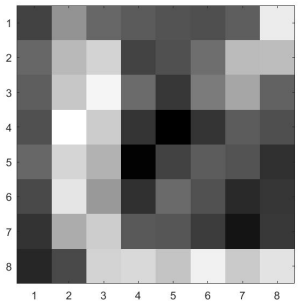
Kuva 23: Yksikkömatriisin avulla Tikhonov-regularisoidun hyväkuntoisen matriisin vaimennuskerroinjakauma. Yksikkömatriisin skalaarikerroin on $\alpha = 10$.



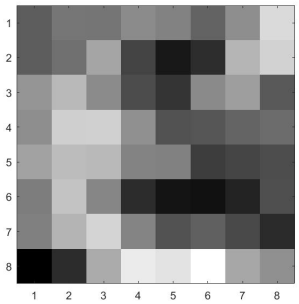
Kuva 24: 1. differenssimatriisin avulla Tikhonov-regularisoidun hyväkuntoisen matriisin vaimennuskerroinjakauma. 1. differenssimatriisin skalaarikerroin on $\alpha = 1$.



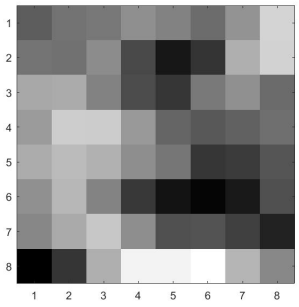
Kuva 25: 1. differenssimatriisin avulla Tikhonov-regularisoidun hyväkuntoisen matriisin vaimennuskerroinjakauma. 1. differenssimatriisin skalaarikerroin on $\alpha = 0,5$.



Kuva 26: 1. differenssimatriisin avulla Tikhonov-regularisoidun hyväkuntoisen matriisin vaimennuskerroinjakauma. 1. differenssimatriisin skalaarikerroin on $\alpha = 1,5$.



Kuva 27: 1. differenssimatriisin avulla Tikhonov-regularisoidun hyväkuntoisen matriisin vaimennuskerroinjakauma. 1. differenssimatriisin skalaarikerroin on $\alpha = 3,5$.



Kuva 28: 1. differenssimatriisin avulla Tikhonov-regularisoidun hyväkuntoisen matriisin vaimennuskerroinjakauma. 1. differenssimatriisin skalaarikerroin on $\alpha = 10$.

Kun hyväkuntoiseen mittausdatan osaan tehdään Tikhonov-regularisointi yksikkömatriisin ja sen skaalauskertoimen avulla (Kuvat 20, 21, 22 ja 23), selkeyttävät L-kuviota vasemmalla sekä alhaalla.

Kun hyväkuntoista matriisia regularisoidaan 1. differenssimatriisin avulla, pienemmillä skalaarikertoimilla α jo aiemmin mainittu L-kuvio tulee selkeästi näkyviin, mutta skalaarikertoimen kasvaessa kuvio muuttuu epäselvemmäksi (Kuvat 24, 25, 26, 27 ja 28).

6 Pohdinta

Aloitetaan tulosten pohdinta koko mittausdatasta muodostetusta vaimennuskerroinjakaumasta (Kuva 8). Siinä näkyy puupalikoiden olinpaikka selkeästi vaaleina kohtina alareunassa, vasemmassa reunassa sekä oikeassa ylänurkassa. Selkeiten kuvio näkyy kuvissa 8 ja 10.

Huonokuntoisen matriisin vaimennuskerroinjakaumasta (Kuva 9) ei pysty erottamaan puupalikoista muodostettua kuviota, ellei tiedä, minkälainen kuvion pitäisi olla. Kun verrataan huonokuntoisen ja hyväkuntoisen vaimennuskerroinjakaumia, niistä huomaa selkeät erot. Huonokuntoisen matriisin kuntoisuusluku oli $1,2 \cdot 10^{17}$, joka on kuntoisuusluvuksi todella suuri.

Hyväkuntoisen matriisin vaimennuskerroinjakaumasta näkee paremmin puupalikkamuodostelmat vasemmasta reunasta alareunaan, sekä oikeassa yläkulmassa. Hyväkuntoisen matriisin kuntoisuusluku oli $1,3 \cdot 10^4$, joka on huomattavan suuri, mutta kuitenkin todella pieni verrattuna huonokuntoisen matriisin kuntoisuuslukuun.

Regularisoinnissa havaittiin suuria muutoksia sekä huonokuntoisen, että hyväkuntoisen matriisin avulla muodostetussa vaimennuskerroinjakaumassa. Molempien matriisien tapauksessa jakauman selkeys parani huomattavasti.

Huonokuntoisen matriisin Tikhonov-regularisointi skaalatulla yksikkömatriisilla vaimennuskerroinjakauma selkeytyy huomattavasti, ja jakaumat näyttävät lähes identtisiltä, vaikka yksikkömatriisin skaalauskerrointa α muutetaan. Kun sama operaatio tehdään skaalatulla 1. differenssimatriisilla, havaitaan, että skalaarin α kasvaessa vaimennuskerroinjakauma muuttuu epätarkemmaksi. Tämä voi johtua siitä, että 1. differenssimatriisin avulla pystytään muodostamaan kuvaus, jonka avulla pystytään tarkastelemaan mittausdatan peräkkäisten alkioiden etäisyyttä. Tässä tapauksessa 1. differenssimatriisin avulla saadaan mittausdatan peräkkäisten alkioiden poikkeama toisistaan. Toisin sanoen, kun skalaaria kasvatetaan, kasvaa myös mittausdatan varianssista johtuva virhe.

Täsmälleen sama efekti voidaan havaita myös hyväkuntoisen matriisin Tikhonov-regularisaatiossa. Skaalatulla yksikkömatriisilla regularisoitu hyväkuntoinen matriisi tuottaa kaikilla skalaarin α arvoilla selkeän ja lähes identtisen vaimennuskerroinjakauman. Skaalatun 1. differenssimatriisin avulla Tikhonov-regularisoidun hyväkuntoisen matriisin vaimennuskerroinjakauma noudattelee lähes samankaltaista kaavaa, kun huonokuntoisella matriisilla. Hyväkuntoisen matriisin vaimennuskerroinjakauma on selkeimmillään, kun skalaari $\alpha = 1,5$. Muutoin skalaarin α kasvaessa vaimennuskerroinjakauma muuttuu epätarkemmaksi.

Lisäksi työssä tutkittiin, minkälainen vaikutus muovikuorella on mittaustuloksiin. Muovikuoren vaimennuskerroin oli $0,09$, joten muovikuorella ei ollut juuri mitään vaikutusta työn lopputuloksiin.

Tämän projektin tuloksista voi sanoa, että jos datasta muodostettu matriisi on yleisesti ottaen huonokuntoinen, niin siihen tehdyt regularisoinnit voivat tuoda lopputulokseen parempaa tarkkuutta. Toisin sanoen dataa ei tarvitse välttämättä olla val-

tavaa määrää tarkan lopputuloksen saamiseksi. On kuitenkin huomioitava, kun matriisia regularisoidaan, on pohdittava huolella, mikä on paras skalaarikerroin regularisointimatriisille. On ymmärrettävä, miten regularisointimatriisi ja sen skaalauskerroin vaikuttaa mittausdataan ja sen ominaisuuksiin.

Viitteet

[1] Superior Urgent Care. X-Ray vs. CT Scan: What's the Difference? — superiorclinics.com. https://www.superiorclinics.com/blog/2022/july/x-ray-vs-ct-scan-whats-the-difference-/, 2022.

[2] Jussi Jauhiainen. Tomografia -demonstraatio. https://elearn.uef.fi/pluginfile.php/917042/mod_resource/content/1/Tomografia_ty%C3%B6ohja.pdf.

[3] R F Kilcoyne, M L Richardson, B A Porter, D O Olson, T K Greenlee, and W Lanzer. Magnetic resonance imaging of soft tissue masses - PubMed — pubmed.ncbi.nlm.nih.gov. https://pubmed.ncbi.nlm.nih.gov/3342555/, 1988.

Liitteet

	A	B	C	D	E	F	G	H	I	J	K	L	M	N	O	P
1	I_0	2196		Measure time 10 s			HV level 991.1									
2	Direct data															
3	0 deg	1533	903	934	1297	1323	1322	1395	0	0	0	0	0	0	0	0
4	26.56 deg	1752	1477	1124	1053	772	955	1361	1523	1256	1075	1155	0	0	0	0
5	45 deg	1871	1820	1464	1047	1161	1112	1099	558	913	1359	1498	1358	1297	1374	0
6	63.435 deg	1773	1444	918	777	1098	1228	1068	826	1376	1468	1444	0	0	0	0
7	90 deg	1917	613	568	1600	1527	1166	1120	1124	0	0	0	0	0	0	0
8	116.565 deg	1781	1442	851	677	856	1015	1510	1323	1432	1222	0	0	0	0	0
9	135 deg	1827	1788	1170	891	900	804	870	885	1143	1761	1442	1443	1318	1346	0
10	153.435 deg	1790	1037	781	819	1232	1173	1222	1116	1376	1210	0	0	0	0	0
11																
12	Conebeam data															
13	voxel 57	777	1101	1310	1617	1337	964	1012	886	765	1052	0	0	0	0	0
14	voxel 64	954	1327	1420	1314	1051	786	836	863	711	665	0	0	0	0	0
15	voxel 8	574	675	914	992	1018	668	681	751	833	1067	0	0	0	0	0
16	voxel 1	913	723	777	705	985	1131	1178	1226	1260	1102	0	0	0	0	0
17	b vox 25 & 33	1222	1326	769	769	765	953	873	822	1099	1115	1003	1201	0	0	0
18	b vox 60 & 61	1212	1033	1068	1358	1228	1193	897	687	739	745	799	863	0	0	0
19	b vox 32 & 40	1161	1195	1171	1265	1351	1293	1270	1261	1370	1317	1276	1327	0	0	0
20	b vox 4 & 5	930	819	886	937	886	1134	1452	1398	1379	1484	1378	1367	0	0	0
21																
22	Testi															
23	b vox 4 & 5	893	836	842	930	861	1099	1383	1385	1351	1416	1343	1373	0	0	0

Kuva 29: Mittauspöytäkirja.